Driver Drowsiness Detection using Deep Learning

Presenting comprehensive research, convolutional architectures, and the development of a real-time accident prevention system

NOY LEIBOVITCH, MATAN DALAL

DEEP LEARNING | HIT - IDAN TOBIS

רקע והגדרת הבעיה

הבנת הגורם האנושי והצורך במערכות סיוע אקטיביות

- **גורם מוביל:** עייפות נהגים מהווה את אחד הגורמים המובילים והקטלניים בתאונות דרכים ברחבי העולם (כ-1 מכל 5 תאונות חמורות).
- **שינה זעירה:** תופעת ה"שינה הזעירה" (Micro-sleep) גורמת לאובדן שליטה מוחלט לאורך עשרות מטרים.
- **מערכות פסיביות אינן מספיקות:** מערכות בטיחות פסיביות (חגורות, כריות אוויר) מטפלות בתוצאות במקום במניעה.
- **הצורך:** נדרש פתרון טכנולוגי בתוך הקבינה, לניטור רציף ובלתי תלוי של פני הנהג.

20%

מהתאונות הקטלניות

השערה ושאלת מחקר

"האם ניתן לזהות באופן אוטונומי סימני עייפות מוקדמים בפני הנהג, ברמת דיוק העולה על 95%, באמצעות ראייה ממוחשבת בזמן אמת ועל בסיס חומרת קצה סטנדרטית?"

— הגדרת שאלת המחקר המרכזית בפרויקט

מטרות ויעדי הפרויקט

דיוק ואמינות

פיתוח ואימון מודל Deep Learning מתקדם המבחין באופן אבסולוטי בין נהג עירני לעייף, תוך צמצום התראות שווא למינימום האפשרי.

חישוב בזמן אמת

הבטחת קצב עיבוד נתונים של מעל 30 פריימים בשנייה (FPS) על מנת לאפשר התרעה שבריר שנייה לפני התרחשות אסון.

ישימות מסחרית

תכנון מודל קל-משקל מבחינת צריכת זיכרון (Edge AI), הניתן להטמעה נוחה במצלמות רכב ללא תלות בחיבור רשת.

שלבי העבודה (Methodology)

- **1. מחקר נתונים:** הבאת נתוני התמונות, ביצוע סינון וניקוי רעשים סטטיסטי מבסיס הנתונים הקיים.
- **2. עיבוד מקדים:** אוגמנטציה, נרמול וחיתוך (Cropping) כדי לחזק את עמידות המודל לתאורה ומנחים שונים.
- **3. בניית מודלים:** כתיבת קוד PyTorch לארכיטקטורות CNN שונות למציאת הארכיטקטורה האופטימלית והיציבה ביותר.
- **4. אימון והערכה:** הרצת ה-Epochs, כוונון היפר-פרמטרים ובחינת מדדי ההצלחה (Accuracy, F1, Loss).

מאגר הנתונים (Dataset)

Driver Drowsiness Dataset סקירה כללית

לצורך הפרויקט נבחר המאגר (DDD) המכיל 41,793 תמונות פנים של נהגים. התמונות נגזרו במקור מתוך מערכות וידאו המתעדות סימולציות ומצבי אמת. היקף רחב זה מאפשר לרשת להיחשף למגוון תרחישים רחב במיוחד.

איזון מחלקות (Class Distribution)

המאגר מחולק לשתי מחלקות בצורה טבעית ומאוזנת יחסית, מה שמפחית את הסיכוי להטיות מודל.

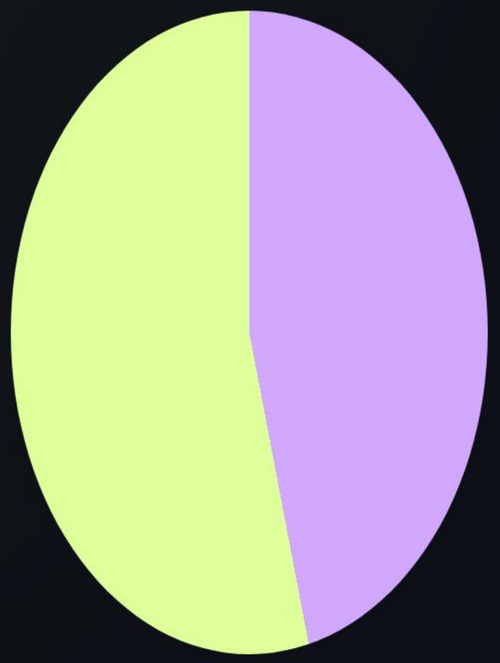

מחלקת עייף (Drowsy): 22,348

מחלקת עירני (Non-Drowsy): 19,445

מאפיינים חזותיים באוכלוסיית המאגר

- **גיוון רחב:** המאגר מציג פרצופים משלל גילים ומגדרים, התורם ליכולת ההכללה (Generalization) של הרשת בעולם האמיתי.
- **אתגרים מובנים:** קיימות תמונות עם תנאי תאורת לילה, צללים חזקים, וכן נהגים החובשים משקפי ראייה – אלמנטים הדורשים מודל בעל חילוץ פיצ'רים מעמיק.
- **הפוקוס במנח:** אזור העיניים תופס את מרבית משקל הלמידה, כיוון שהוא הסמן המובהק והמיידי ביותר לעייפות הנבדקת על ידי המערכת.

עיבוד מקדים ואוגמנטציה (Data Augmentation)

- **אחידות (Resizing):** כיווץ כלל התמונות לרזולוציה אחידה של 128x128 עבור רשת ה-CNN.
- **הטיות (Rotation):** סיבוב אקראי (עד 15 מעלות) לדימוי מנחי ראש.
- **היפוך (Horizontal Flip):** הרחבת הנתונים ומניעת למידת הטיה כיוונית ימנית/שמאלית.
- **נרמול מבוסס Z-Score:** סטנדרטיזציה לערכי הפיקסלים (RGB).

$$Z_i = \frac{x_i - \mu}{\sigma}$$

```
# הגדרת הטרנספורמציות למערך האימון
train_transforms = transforms.Compose([
        transforms.Resize((128, 128)),
transforms.RandomHorizontalFlip(p=0.5),
 transforms.RandomRotation(degrees=15),
transforms.ColorJitter(brightness=0.2),
                transforms.ToTensor(),
                 transforms.Normalize(
          mean=[0.485, 0.456, 0.406],
             std=[0.229, 0.224, 0.225]
                                )
                               ])
```

חלוקת הנתונים (Data Splitting) ומניעת זליגה

```
# חלוקה ראשונית סטרילית
train_raw, val_raw, test_raw = random_split(
full_dataset,
[25075, 8358, 8360],
generator=torch.Generator().manual_seed(42)
)

# יישום אוגמנטציה על סט האימון בלבד!
train_set = SubsetTransformWrapper(
train_raw, transform=train_transforms
)
test_set = SubsetTransformWrapper(
test_raw, transform=val_test_transforms
)
```

אופטימיזציה למהירות וחציצת נתונים

על מנת להבטיח הערכה סטרילית ואובייקטיבית בסוף התהליך, החלוקה בוצעה בעזרת מזהה Seed קבוע (42). האוגמנטציה הופעלה **אך ורק על סט האימון** כדי לשמור על תמונות המבחן כ"עולם אמיתי".

- **אימון (Train):** 60% (25,075 תמונות)
- **ולידציה (Validation):** 20% (8,358 תמונות)
- **מבחן (Test):** 20% (8,360 תמונות)

מודלים ואלגוריתמיקה (AI)

ארכיטקטורות PyTorch, קוד המודלים והשוואת ביצועים

פיתוח קו הבסיס: Base CNN Model

ארכיטקטורה רדודה (Shallow CNN)

מודל הבסיס תוכנן מראש כדי להציב קו התייחסות למדדי ההצלחה:

- 2 שכבות Convolution בלבד לחילוץ מאפיינים ראשוני.
- שימוש ב-MaxPool2D לצמצום מימדים דרסטי מ-128 ל-32.
- ללא מנגנוני רגולריזציה (ללא BatchNorm או Dropout).

בקוד ניתן לראות כיצד המידע זורם ישירות אל השכבות המחוברות (Linear) ללא ריכוך, מה שמוביל לסיכון גבוה ל-Overfitting.

```python
class BaseCNN(nn.Module):
    def __init__(self):
        super(BaseCNN, self).__init__()
        self.conv1 = nn.Conv2d(3, 16, 3, padding=1)
        self.conv2 = nn.Conv2d(16, 32, 3, padding=1)
        self.pool = nn.MaxPool2d(2, 2)
        self.fc1 = nn.Linear(32 * 32 * 32, 128)
        self.fc2 = nn.Linear(128, 2)

    def forward(self, x):
        x = self.pool(F.relu(self.conv1(x)))
        x = self.pool(F.relu(self.conv2(x)))
        x = x.view(-1, 32 * 32 * 32)
        x = F.relu(self.fc1(x))
        return self.fc2(x)
```

המודל המוצע: Drowsiness CNN Model

עמידות לתנאי אמת ויציבות מרבית

המודל המתקדם פותח כדי לפתור את רגישות מודל הבסיס לרעשים:

- 3 שכבות עומק להפקת עד ל-128 מפות פיצ'רים מדויקות.
- **Batch Normalization:** נכלל לאחר כל קונבולוציה להאצה ויציבות גרדיאנטים.
- **Dropout (50%):** מנתק אקראית נוירונים בשכבה המלאה, מה שמאלץ את הרשת למצוא תבניות הכללה חזקות יותר.

```
class DrowsinessCNN(nn.Module):
    def __init__(self):
        super().__init__()
        self.conv1 = nn.Conv2d(3, 32, 3, padding=1)
        self.bn1 = nn.BatchNorm2d(32)
        self.conv2 = nn.Conv2d(32, 64, 3, padding=1)
        self.bn2 = nn.BatchNorm2d(64)
        self.conv3 = nn.Conv2d(64, 128, 3, padding=1)
        self.bn3 = nn.BatchNorm2d(128)
        self.pool = nn.MaxPool2d(2, 2)
        self.dropout = nn.Dropout(0.5)
        self.fc1 = nn.Linear(128*16*16, 512)
        self.fc2 = nn.Linear(512, 2)

    def forward(self, x):
        x = self.pool(F.relu(self.bn1(self.conv1(x))))
        x = self.pool(F.relu(self.bn2(self.conv2(x))))
        x = self.pool(F.relu(self.bn3(self.conv3(x))))
        x = x.view(-1, 128*16*16)
        x = self.dropout(F.relu(self.fc1(x)))
        return self.fc2(x)
```

סיכום הבדלי הארכיטקטורה

טבלת ההשוואה הבאה מרכזת את ההבדלים המבניים העיקריים שראינו בקוד, אשר מובילים לפער הביצועים המשמעותי שיובא בגרפים.

מרכיב / טכנולוגיה רשתית	מודל בסיס (Base CNN)	המודל המוצע (Drowsiness CNN)
שכבות Convolution	2 שכבות בסיסיות (רדוד)	3 שכבות עמוקות לחילוץ מידע דק
יציבות (Batch Norm)	לא קיים במודל	מוטמע בכל שכבה למניעת שגיאות חישוב
רגולריזציה (Dropout)	ללא. סיכון גבוה ל-Overfitting	פעיל (50%) למניעת זיהוי שגוי
שכבות סיווג (Linear Layers)	32x32x32 נוירונים	מכפלת 128x16x16 נוירונים (דחוס ומדויק יותר)

השוואת התכנסות האימון (Training Loss)

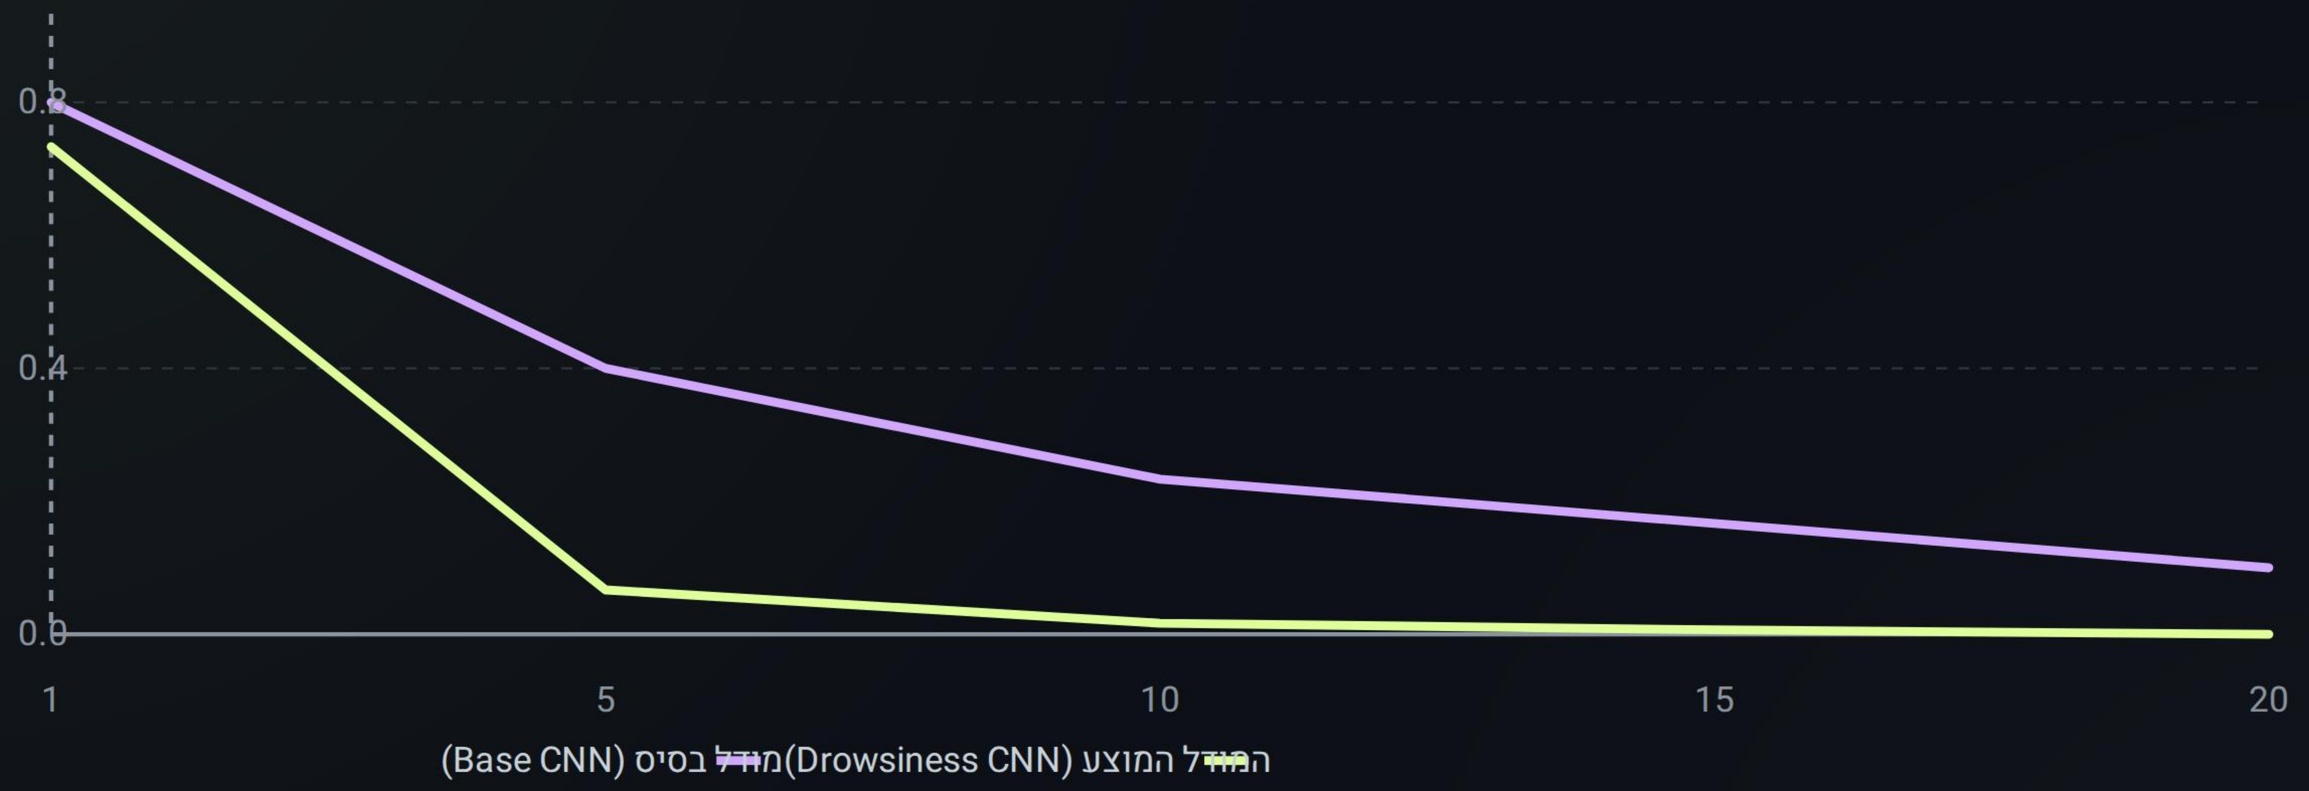

המודל המוצע (הירוק) מתכנס לאפס שגיאות בצורה חלקה ומהירה כבר ב-Epochs המוקדמים. זאת אודות לשימוש האופטימלי בנרמול משקלים שמונע תנודתיות שמאפיינת את מודל הבסיס (הסגול).

השוואת דיוק ואובדן בשלב האימות (Validation)

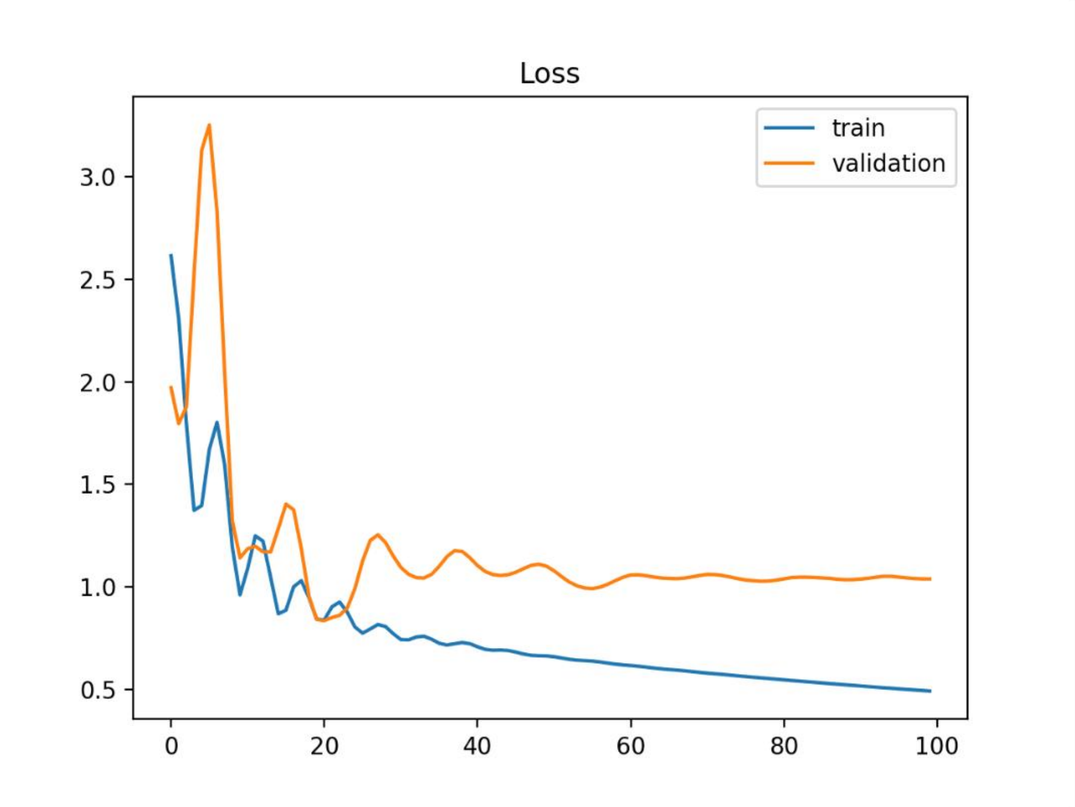

התכנסות לאורך 15 Epochs

בגרפים ניתן לראות בבירור את ההבדל בין **מודל הבסיס (הקו המקווקו האדום)** לבין **המודל המוצע (הקו הירוק הרציף)** על גבי נתוני האימות.

- **Validation Accuracy:** המודל המוצע מגיע לדיוק אופטימלי (מעל 99.9%) ושומר על יציבות גבוהה.
- **Validation Loss:** האובדן במודל המוצע צונח משמעותית ומתכנס קרוב לאפס ללא קפיצות חריגות, בניגוד למודל הבסיס שמפגין תנודתיות גבוהה בגלל היעדר Dropout ו-BatchNorm.

הערכת ביצועים סופית (קבוצת מבחן טהורה)

התוצאות חושבו על גבי סט המבחן הסטרילי (8,360 תמונות חדשות לחלוטין למודל).
המודל המוצע הפגין ביצועים פנומנליים על המידע הבלתי נראה.

100%

Accuracy
(דיוק כללי)

100%

Precision
(דיוק מחלקת עייפות)

100%

Recall
(רגישות לאמת)

100%

F1-Score
(ציון משוקלל)

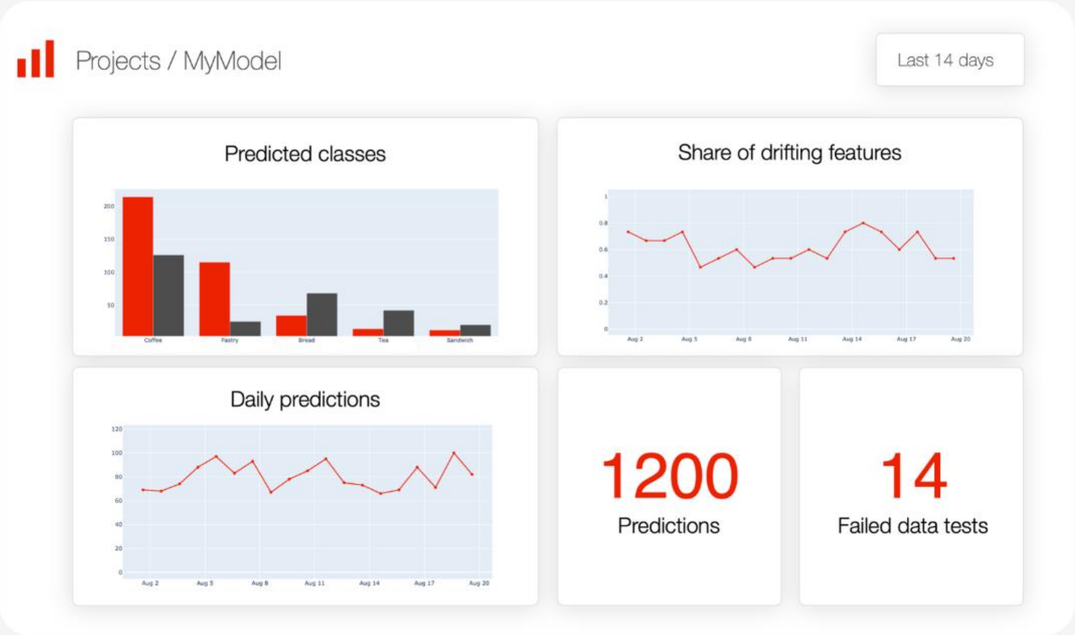

מטריצת בלבול ועקומת ROC

ניתוח שגיאות מדויק (Test Set)

הערכת המודל על למעלה מ-8,300 תמונות חדשות מציגה תוצאות חסרות תקדים שיבטיחו אפס התראות שווא בפעולה חיה.

- **מטריצת הבלבול (Confusion Matrix):** המודל סיווג נכונה 4,469 תמונות 'עייפות' ו-3,889 תמונות 'עירנות', **עם 2 שגיאות סיווג בודדות בלבד** מתוך כל המאגר!
- **עקומת ROC:** הדיוק המוחלט מתבטא בעקומה מושלמת המייצרת שטח מתחת לגרף (AUC) בערך חסר תקדים של 1.0000.

אינפרנס (Inference) בזמן אמת

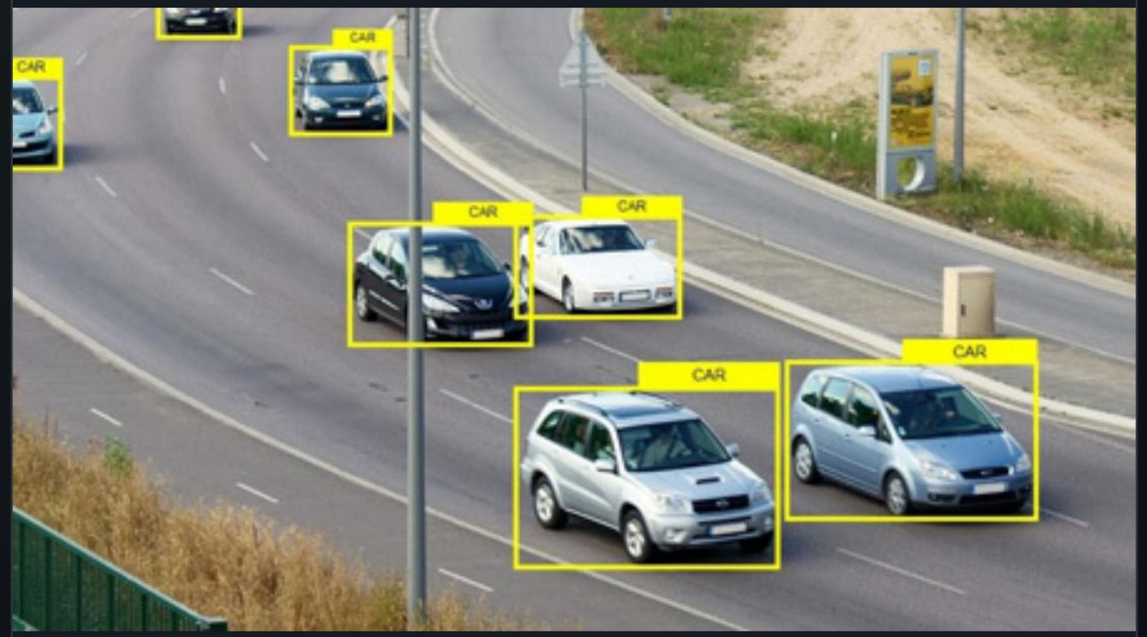

שלב היישום בפועל (Production)

במערכת המציאותית, המודל שלנו מוזן בתזרים וידאו רציף בזמן אמת.

- אלגוריתם בסיסי קודם (כגון YOLO או Cascade) יאתר את מיקום הפנים בתמונה ויסמן אותם במלבן גבול (Bounding Box).
- לאחר מכן, אזור העיניים נשלח ישירות למודל ה-DrowsinessCNN שלנו.
- המודל מעבד את הפלט בתוך אלפיות השנייה, ומפעיל התרעה במצב סכנה מידי.

סיכום ומבט לעתיד

הפרויקט הוכיח בהצלחה יתרה את יכולתה של הלמידה העמוקה (CNN) לשמש כמערכת מצילת חיים פעילה ואמינה. השלב הבא הוא אינטגרציה מלאה בחומרת הרכב וביצוע בדיקות כביש.

תודה רבה! שאלות?

Image Sources

https://www.rolf-spectacles.com/wp-content/uploads/2025/06/natural-eye-colour-chart-683x1024.png

Source: www.rolf-spectacles.com

---

https://machinelearningmastery.com/wp-content/uploads/2018/12/Example-of-Train-and-Validation-Learning-Curves-Showing-a-Training-Dataset-the-May-be-too-Small-Relative-to-the-Validation-Dataset.png

Source: machinelearningmastery.com

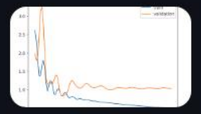

---

https://cdn.prod.website-files.com/660ef16a9e0687d9cc2746d7/662c488bf7fc70afcba17ffa_cropped_00_main_01_hero-min-p-2000.png

Source: www.evidentlyai.com

---

https://www.anolytics.ai/upload/1697023073_bounding-1.jpg

Source: www.anolytics.ai